

RoadScan-MA

Choix des 5 Datasets — Justification Complete

Bases sur les résultats de la recherche automatique : 88 requêtes x 4 sources x 22 mots-clés

Projet	RoadScan-MA — Detection des degradations routieres
Equipe	Mohamed Amine Belasri — ENSAM Meknes, Filiere IATD
Annee	2025 / 2026
Modele	YOLOv8s fine-tune sur routes marocaines
Recherche	167 datasets trouves → 5 selectionnes → autres elimines

Sommaire
1. Resultats bruts de la recherche automatique
2. Les 5 datasets selectionnes — justification detaillee
3. Pourquoi les autres datasets ont ete elimines
4. La combinaison finale et comment l'utiliser

1. Resultats bruts de la recherche automatique

La recherche automatique a ete lancee avec 22 mots-cles sur 4 sources simultanement (Kaggle, Roboflow, Papers With Code, Google Dataset Search). Elle a retourne 278 resultats bruts, reduits a 167 datasets uniques apres deduplication. La recherche a dure 67 secondes au lieu des 145 secondes estimees.

Repartition par source :

Source	Datasets trouves	Observation
Kaggle	123	Tres riche — resultats les plus precis
Roboflow	22	1 lien de recherche YOLOv8 par mot-cle
PapersWithCode	0	API bloquee depuis Colab — pas de resultats
GoogleDataset	22	1 lien de recherche par mot-cle
TOTAL UNIQUE	167	Apres suppression des doublons

Top 20 datasets retournees par le score automatique :

#	Source	Titre	DL	Qualite	Score
1	Kaggle	Surface Crack Detection	26823	0.9375	13
2	Kaggle	Pothole Detection (andrewmvd)	7919	0.875	13
3	Kaggle	Annotated Potholes Image Dataset	6230	0.875	13
4	Roboflow	[Recherche] pothole detection yolov8	Voir	YOLO	13
5	Roboflow	[Recherche] pavement crack detection	Voir	YOLO	13
6	Roboflow	[Recherche] crack detection annotated	Voir	YOLO	13
7	Kaggle	Pothole Detection Dataset (rajdalsaniya)	4051	0.875	11
8	Roboflow	[Recherche] road damage detection	Voir	YOLO	11
9	Roboflow	[Recherche] pavement damage detection	Voir	YOLO	11
10	Kaggle	surface-defect-detection-dataset	6099	0.8125	11
11	Roboflow	[Recherche] road crack detection	Voir	YOLO	11
12	Kaggle	Pothole Detection Dataset (12827 DL)	12827	0.8125	11
13	Kaggle	Potholes-Detection-YOLOv8	2500	0.8125	11
14	Kaggle	Pothole Image Data-Set	8779	0.875	11
15	Kaggle	Annotated Potholes with Severity Levels	1171	1.0	11
16	Roboflow	[Recherche] pothole detection	Voir	YOLO	11
17	Roboflow	[Recherche] pothole annotated dataset	Voir	YOLO	11
18	Roboflow	[Recherche] asphalt crack detection	Voir	YOLO	11
19	Kaggle	Structural Defects Network SDNET 2018	9061	0.875	11
20	Kaggle	Concrete and Pavement Crack Dataset	2610	0.875	11

Lignes vertes = datasets selectionnees dans notre choix final. Ligne jaune = dataset interessant pour la severite.

2. Les 5 datasets selectionnes — justification detaillee

Parmi les 167 datasets uniques trouves, voici les 5 retenus pour construire le meilleur modele RoadScan-MA. Chaque choix est justifie par des criteres mesurables : score, telechargements, usabilite, format, et pertinence pour les routes marocaines.

Dataset 1 — aliabdelmenam/rdd-2022 — RDD2022

Role : Base principale d'entrainement | Phase : Phase 1 — Entrainement de base

Score automatique : 9/15 (score automatique sous-estime car absent du TOP20 Kaggle)

Critere	Valeur
Taille	10.6 GB
Images	47 420 images annotees
Pays	6 pays (Japon, Inde, USA, Norvege, Chine, Tcheque)
Format	YOLO + Pascal VOC + COCO
Telechargements	7 463
Usabilite Kaggle	0.6875 / 1

Pourquoi ce dataset est retenu :

- C'est LE dataset de reference mondial pour les degradations routieres — cite dans 50+ publications
- 47 420 images = la plus grande base disponible gratuitement
- Contient exactement les 4 classes dont on a besoin : D00, D10, D20, D40
- Les images indiennes (7 706 img) sont les plus proches des conditions marocaines
- Disponible directement via l'API Kaggle depuis Colab en 1 commande
- Score sous-estime car la recherche 'RDD2022' retourne 21 resultats Kaggle mais le dataset specifique est aliabdelmenam/rdd-2022

Dataset 2 — arunrk7/surface-crack-detection — Surface Crack Detection

Role : Complement pour les fissures (D00, D10, D20) | Phase : Phase 1 — Complement fissures

Score automatique : 13/15 — MEILLEUR SCORE du classement

Critere	Valeur
Taille	Non precise (dataset image)
Telechargements	26 823 — LE PLUS TELECHARGEE du classement
Usabilite Kaggle	0.9375 — MEILLEUR SCORE d'usabilite
Classes	Fissures sur surfaces (beton, asphalte)
Format	Images classifiees
Position	#1 dans notre classement automatique

Pourquoi ce dataset est retenu :

- Score automatique 13/15 = meilleur dataset trouve sur les 167
- 26 823 telechargements = valide et teste par toute la communaute CV
- Usabilite 0.9375 = annotations propres et documentation excellente

- Complémente RDD2022 sur les classes de fissures D00 et D10
- Très utile pour le fine-tuning car les fissures sur asphalte marocain sont similaires

Dataset 3 — chitholian/annotated-potholes-dataset — Annotated Potholes

Role : Spécialise nids-de-poule (D40) — la classe la plus critique | Phase : Phase 1 — Complément nids-de-poule

Score automatique : 13/15 — Egalité avec le dataset 2

Critère	Valeur
Taille	Non précisée
Telechargements	6 230
Usabilité Kaggle	0.875
Classes	Nids-de-poule avec bounding boxes
Format	Annoté avec bounding boxes
Position	#3 dans notre classement automatique

Pourquoi ce dataset est retenu :

- Score 13/15 = excellent, partage la 1^{ère} place avec Surface Crack Detection
- Spécialise sur D40 (nids-de-poule) = la dégradation la plus dangereuse pour les routes marocaines
- 6 230 téléchargements = bien validé par la communauté
- Usabilité 0.875 = annotations fiables et propres
- Complémente RDD2022 qui sous-représente les nids-de-poule profonds

Dataset 4 — Annotated Potholes with Severity Levels (position 15 du classement)

Role : Score de sévérité — valeur ajoutée unique de RoadScan-MA | Phase : Phase 2 — Fine-tuning avec sévérité

Score automatique : 11/15 mais USABILITE PARFAITE 1.0/1

Critère	Valeur
Usabilité Kaggle	1.0 / 1 — PARFAIT — le seul dataset avec usabilité maximale
Telechargements	1 171
Particularité	Nids-de-poule AVEC niveaux de sévérité annotés
Classes	Pothole léger / modéré / critique
Format	Bounding boxes + label de sévérité
Position	#15 dans notre classement automatique

Pourquoi ce dataset est retenu :

- UNIQUE dans notre liste : seul dataset avec des niveaux de sévérité pré-annotés
- Usabilité 1.0/1 = documentation parfaite, données parfaitement propres
- Répond directement au besoin de scoring RoadScan-MA (léger / modéré / critique)
- Sans ce dataset, le score de sévérité doit être calculé géométriquement
- Avec ce dataset, YOLOv8 peut apprendre directement à classer la sévérité
- Valeur ajoutée différenciante que les autres projets CV n'ont pas

Dataset 5 — Roboflow Universe — pothole detection yolov8 (format natif)

Role : Format YOLOv8 natif — zero conversion | Phase : Phase 3 — Integration directe YOLOv8

Score automatique : 13/15 (positions 4, 5, 6 du classement)

Critere	Valeur
Source	universe.roboflow.com
Format	YOLOv8 natif — zero preprocessing
Contenu	Plusieurs datasets fusionnes, deja nettoyes
Avantage	Export direct compatible Ultralytics
Mots-cles	pothole detection yolov8 / pavement crack detection
Position	#4, #5, #6 dans notre classement automatique

Pourquoi ce dataset est retenu :

- Format YOLOv8 natif = aucune conversion d'annotations necessaire
 - Positions 4, 5 et 6 dans notre classement = tres pertinent
 - Roboflow agrege et nettoie automatiquement les donnees avant export
 - Gain de temps important : telecharger et entrainer sans preprocessing
 - Permet de tester rapidement le pipeline avant d'utiliser les grands datasets
-

3. Pourquoi les autres datasets ont ete elimines

Sur les 167 datasets uniques trouves, 162 ont ete elimines. Voici les raisons d'elimination par categorie, avec des exemples concrets pris dans les resultats de la recherche automatique.

Raison 1 — Hors sujet (pas de degradations routieres)

De nombreux datasets retournes par la recherche parlent d'accidents de voitures, de trafic, de securite routiere — mais pas de l'etat physique de la chaussee.

Dataset	Probleme identifie	Raison d'elimination
traffic-accidents (oktayrdeki)	Accidents de voiture	Hors sujet — pas de degradations physiques
Traffic Accident Prediction	Prediction d'accidents	Hors sujet — pas de chaussee
Chicago Traffic Crashes	Donnees police Chicago	Hors sujet — donnees tabulaires
crash-data-queensland	Accidents Queensland	Hors sujet — pas de computer vision
Indian Cities AQI	Qualite de l'air	Complettement hors sujet

Raison 2 — Trop specifique (une seule classe)

Certains datasets ne couvrent qu'une seule classe alors que RoadScan-MA a besoin des 4 classes D00, D10, D20, D40.

Dataset	Probleme identifie	Raison d'elimination
bridge-cracks-image (yidazhang07)	Fissures de ponts uniquement	Hors contexte routier
SDNET2018 Structural Defects	Betons de structures	Pas de routes — ponts et murs
Concrete and Pavement Crack	Beton generique	Pas specifique aux routes
RAD Road Anomaly Detection	Anomalies generiques	Trop generique, pas de bounding boxes

Raison 3 — Mauvaise usabilite (annotations non fiables)

Les datasets avec usabilite inferieure a 0.5 ont ete elimines car leur qualite d'annotation est insuffisante pour entrainer un modele fiable.

Dataset	Probleme identifie	Raison d'elimination
road-damage-detection (youssefhany100)	Usabilite 0.176 / 1	Annotations de mauvaise qualite
road-damage (alvarobasily)	Usabilite 0.75 mais date 2020	Trop vieux, conditions differentes
road damage (tudorfrecus)	41 telechargements seulement	Tres peu valide par la communaute
nguyenuhau/road-damage-dataset	67 telechargements	Pas assez teste

Raison 4 — Doublon avec nos datasets selectionnes

Certains datasets couvrent exactement le meme contenu que nos 5 datasets selectionnes. Les garder en plus n'apporterait pas de diversite supplementaire.

Dataset	Probleme identifie	Raison d'elimination
Pothole Detection Dataset (12827 DL)	Similaire au dataset 3 selectionne	Doublon — meme classe, meme format

Potholes-Detection-YOLOv8 (2500 DL)	YOLOv8 déjà couvert par Roboflow	Doublon — Roboflow est plus complet
Pothole Image Data-Set (8779 DL)	Similaire au dataset 3	Doublon — pas de valeur ajoutée
Pothole Detection Dataset (rajdalsaniya)	Sous-ensemble de RDD2022	Déjà couvert par RDD2022

Raison 5 — Format incompatible ou inaccessible

Certains datasets existent mais leur format ou leur accessibilité les rend difficiles à utiliser dans le projet RoadScan-MA.

Dataset	Problème identifié	Raison d'élimination
RescueNet (yaroslavchyrko)	23 GB — beaucoup trop lourd	Surcharge Colab et Drive
Car-Vehicle Crash (balanced)	Images de crashes, pas de chaussée	Format vidéo, pas d'images
PapersWithCode : 0 résultats	API bloquée depuis Colab	Inaccessible pendant la recherche
Roboflow sans clé API	Liens de recherche uniquement	Résultats partiels sans clé API

4. La combinaison finale et comment l'utiliser

Recapitulatif des 5 datasets selectionnes :

#	Dataset	Role	Phase	Images	Avantage cle
1	RDD2022 (aliabdelmenam)	Base principale	Phase 1	47 420	47K images 6 pays
2	Surface Crack (arunrk7)	Fissures D00/D10	Phase 1	Variable	Score 13/15 26K telecharg.
3	Annotated Potholes (chitholian)	Nids-de-poule D40	Phase 1	Variable	Score 13/15 Bien annote
4	Pothole Severity Levels	Scoring severite	Phase 2	Variable	Usabilite 1.0 Severite incluse
5	Roboflow pothole yolov8	Format YOLOv8	Phase 3	Variable	Zero conversion Score 13/15

Pipeline d'utilisation des 5 datasets :

Phase 1 — Entrainement de base (Google Colab) | Datasets 1 + 2 + 3

```
!kaggle datasets download -d aliabdelmenam/rdd-2022
!kaggle datasets download -d arunrk7/surface-crack-detection
!kaggle datasets download -d chitholian/annotated-potholes-dataset
model = YOLO('yolov8s.pt')
model.train(data='combined_dataset.yaml', epochs=100)
```

Resultat : mAP attendu : 0.50 a 0.60

Phase 2 — Fine-tuning avec severite | Dataset 4 + Images marocaines Meknes

```
# Ajouter les images marocaines collectees sur le terrain
# Ajouter le dataset Pothole Severity Levels
model.train(data='severity_dataset.yaml', epochs=30)
```

Resultat : mAP attendu : 0.55 a 0.70 + score de severite

Phase 3 — Validation YOLOv8 natif | Dataset 5 (Roboflow)

```
# Telecharger depuis Roboflow Universe
# Format YOLOv8 natif – zero conversion
model.val(data='roboflow_dataset.yaml')
```

Resultat : Validation finale — mAP cible >= 0.55

Pourquoi cette combinaison est la meilleure pour RoadScan-MA

Diversite maximale (47K images, 6 pays) + Qualite des annotations (usabilite 0.875-1.0) + Format YOLOv8 natif (zero conversion) + Scoring de severite (unique dans notre liste) + Adaptation locale marocaine (dataset Meknes)