

RoadScan-MA

Guide Complet — Choisir la Meilleure Data

Pour entraîner YOLOv8 sur les dégradations routières marocaines

Projet	RoadScan-MA — Detection des degradations routieres
--------	--

Ecole	ENSAM Meknes — Filiere IATD
-------	-----------------------------

Annee	2025 / 2026
-------	-------------

Modele	YOLOv8s — fine-tuning sur routes marocaines
--------	---

Sommaire

1. Pourquoi la qualite de la data est primordiale
2. Les 3 datasets recommandes pour RoadScan-MA
3. Les 6 criteres pour evaluer n'importe quel dataset
4. Les meilleures sources sur internet
5. Les mots-cles de recherche
6. La combinaison optimale de datasets
7. Comment telecharger dans Google Colab
8. Tableau de decision rapide

1. Pourquoi la qualite de la data est primordiale

En Computer Vision, la qualite du modele YOLOv8 depend directement et uniquement de la qualite des donnees utilisees pour l'entrainement. Un modele entraine sur de mauvaises donnees donnera de mauvais resultats, peu importe son architecture.

Garbage In = Garbage Out

Mauvaise data → Mauvais modele → Systeme inutilisable

Ce qu'une bonne data apporte a RoadScan-MA :

Element	Impact sur RoadScan-MA
Detection precise	Le modele reconnait vraiment D00, D10, D20, D40 sur les routes marocaines
Moins d'erreurs	Peu de faux positifs (detecter une ombre comme un nid-de-poule)
Generalisation	Le modele fonctionne sur des routes qu'il n'a jamais vues
Score mAP eleve	mAP >= 0.55 possible avec une bonne combinaison de datasets

2. Les 3 datasets recommandes pour RoadScan-MA

Dataset : aliabdelmenam/rdd-2022

Role : Dataset principal — base de l'entrainement

Source	Kaggle	Taille	10.6 GB
Images	47 420	Format	YOLO + Pascal VOC + COCO
Usabilite	0.6875 / 1	Telechargements	7 463
Fraicheur	Fevrier 2025	Pays	6 pays (Japon, Inde, USA, Norvege, Chine, Tcheque)

Pourquoi ce dataset est recommande :

- Le plus grand dataset public de degradations routieres au monde
 - Dataset officiel de reference utilise par toute la communaute CV
 - 47 420 images = base solide pour apprendre les 4 classes D00/D10/D20/D40
 - Les images indiennes sont proches des conditions marocaines (chaleur, poussiere)
-

Dataset : lorenzoarcioni/road-damage-dataset

Role : Dataset complementaire — propre et recent

Source	Kaggle	Taille	194 MB
Images	~2 000	Format	YOLO ready
Usabilite	0.875 / 1	Telechargements	2 217
Fraicheur	Fevrier 2026	Pays	International

Pourquoi ce dataset est recommande :

- Meilleur score d'usabilite (0.875) = donnees propres et bien annotees
 - Mis a jour en fevrier 2026 = donnees les plus recentes disponibles
 - Contient nids-de-poule + fissures + regards (diversite de classes)
 - Leger (194 MB) = telechargement rapide, pas d'espace disque gaspille
-

Dataset : cubeai/road-damage-detection-for-yolov8

Role : Dataset YOLOv8 — zero conversion necessaire

Source	Kaggle	Taille	5.9 GB
Images	Large	Format	YOLOv8 natif
Usabilite	0.375 / 1	Telechargements	186
Fraicheur	Avril 2024	Pays	International

Pourquoi ce dataset est recommande :

- Seul dataset deja formate specifiquement pour YOLOv8

- Zero conversion d'annotations — tu charges et tu entraines directement
 - Gain de temps important (pas de preprocessing supplémentaire)
 - Utile pour tester rapidement le pipeline avant d'optimiser
-

3. Les 6 criteres pour evaluer n'importe quel dataset

Avant de choisir un dataset sur internet, verifie toujours ces 6 criteres dans l'ordre. Un dataset qui ne passe pas les 4 premiers criteres doit etre evite.

Critere 1 — Usabilite (Usability Rating)

Sur Kaggle, ce score mesure la qualite de la documentation, la lisibilite du code et la proprete des donnees.

Niveau	Description	Recommandation
0.875 ou plus	Excellent — utilise sans hesitation	OK
0.75 a 0.874	Bon — utilisable avec precaution	Prudence
0.5 a 0.749	Mediocre — verifier manuellement les annotations	Non
Moins de 0.5	Mauvais — eviter ou re-annoter entierement	Non

Critere 2 — Nombre de telechargements

Un dataset tres telecharge a ete teste par beaucoup de personnes. Les problemes sont generalement signales dans les commentaires.

Niveau	Description	Recommandation
Plus de 5 000	Tres populaire et valide par la communaute	OK
1 000 a 5 000	Populaire et fiable	Prudence
100 a 999	Peu teste — verifier les commentaires	Non
Moins de 100	Tres peu teste — risque eleve de problemes	Non

Critere 3 — Fraicheur des donnees

Pour RoadScan-MA, la fraicheur est importante car les techniques d'annotation et les conditions des routes evoluent.

Niveau	Description	Recommandation
Moins de 1 an	Tres recent — reflète les conditions actuelles	OK
1 a 2 ans	Acceptable pour la plupart des projets	Prudence
2 a 4 ans	Correct mais peut manquer de diversite recente	Non
Plus de 4 ans	Vieux — technologies et conditions ont change	Non

Critere 4 — Format des annotations

YOLOv8 utilise le format YOLO (.txt). Un dataset dans un autre format necessite une etape de conversion.

Niveau	Description	Recommandation
Format YOLO (.txt)	Parfait — compatible directement avec YOLOv8	OK
Pascal VOC (.xml)	Acceptable — conversion simple avec un script Python	Prudence

COCO (.json)	Acceptable — conversion disponible via Roboflow	Prudence
Sans annotations	A éviter — il faut tout annoter manuellement	Non

Critere 5 — Proximite avec le contexte marocain

Les routes marocaines ont des caracteristiques specifiques : chaleur intense, poussiere, asphalte degrade par les ecart de temperature.

Niveau	Description	Recommandation
Inde, Proche-Orient, Afrique	Excellent — conditions climatiques similaires	OK
USA, Europe du Sud	Bon — quelques similitudes	Prudence
Europe du Nord, Canada	Moyen — routes trop bien entretenues	Non
Arctique, zones de gel	Mauvais — conditions totalement differentes	Non

Critere 6 — Taille vs qualite

Un grand dataset de mauvaise qualite peut degrader les performances du modele. La qualite prime toujours sur la quantite.

Niveau	Description	Recommandation
Grand ET bien note	Ideal — grand volume + bonne qualite	OK
Grand mais mal note	Verifier manuellement avant d'utiliser	Prudence
Petit mais bien note	Excellent complement pour le fine-tuning	Prudence
Petit ET mal note	Inutile — n'apportera rien au modele	Non

4. Les meilleures sources de datasets sur internet

Niveau 1 — Plateformes generalistes

Source	URL	Description	Note
Kaggle	kaggle.com	Le plus grand marche de datasets. Filtrage par usabilite, popularite, format. API pour Colab.	★★★★
Roboflow Universe	universe.roboflow.com	Specialise Computer Vision. Datasets deja formates pour YOLOv8. Export direct.	★★★★★
Papers With Code	paperswithcode.com/datasets	Datasets lies a des publications scientifiques. Benchmarks disponibles.	★★★★★

Niveau 2 — Plateformes academiques

Source	URL	Description	Note
Zenodo	zenodo.org	Plateforme de la Commission Europeenne. DOI officiel = source citeable.	★★★★
IEEE DataPort	ieee-dataport.org	Datasets valides scientifiquement. Associes a des publications IEEE.	★★★★★
Mendeley Data	data.mendeley.com	Plateforme academique d'Elsevier. Datasets peer-reviewed. Gratuit.	★★★★

Niveau 3 — GitHub et moteurs de recherche

Source	URL	Description	Note
GitHub	github.com	Chercheurs publient leurs datasets. Gratuit et open source.	★★★
Google Dataset Search	datasetsearch.research.google.com	Moteur de recherche dedie aux datasets. Aggrege tous les datasets du web.	★★★
arXiv	arxiv.org	Archive des papiers de recherche. Les papiers mentionnent leur dataset.	★★★

5. Les mots-cles de recherche

Utilise ces mots-cles sur les plateformes listees ci-dessus pour trouver les meilleurs datasets. Les recherches en anglais retournent beaucoup plus de resultats.

Categorie	Mots-cles	Plateforme recommandee
General	road damage detection dataset pavement crack detection annotated	Kaggle, Roboflow
YOLOv8 specifique	road damage yolov8 pothole detection yolov8 format	Roboflow Universe
Nids-de-poule	pothole detection dataset pothole annotated bounding box	Kaggle, Roboflow
Fissures	asphalt crack detection road surface defect dataset	Kaggle, Papers With Code
Contexte africain	road damage Africa dataset pavement detection Morocco road damage Middle East	Google Dataset Search, Zenodo
Academique	road damage detection deep learning 2024 pavement distress detection CNN	arXiv, Papers With Code
Francais	dataset degradations routieres detection nids de poule dataset	Google Dataset Search

Conseil de recherche avancee :

- Sur Kaggle : apres la recherche, filtre par "Usability Rating" > 0.7 et "Downloads" > 500
- Sur Roboflow : filtre par "Object Detection" et "YOLO v8 PyTorch" pour avoir le format direct
- Sur Papers With Code : cherche les articles recents (2023-2024) et clique sur "Datasets" pour trouver les donnees
- Sur GitHub : cherche "road damage dataset site:github.com" sur Google pour des resultats plus precis

6. La combinaison optimale de datasets

Pour obtenir le meilleur modele RoadScan-MA possible, utilise ces datasets en 3 phases successives. Chaque phase ameliore la precision et la robustesse du modele.

Phase 1 — Entrainement de base

Le modele apprend a reconnaitre les 4 types de degradations en general.

- + aliabdelmenam/rdd-2022 (47 420 images de 6 pays)
- + lorenzoarcioni/road-damage-dataset (2 000 images propres)

Resultat : mAP attendu : 0.50 a 0.60

Phase 2 — Fine-tuning marocain

Le modele s'adapte aux conditions specifiques des routes marocaines : asphalte local, chaleur, poussiere saharienne.

- + Tes 200 a 500 images collectees sur les routes de Meknes
- + Annotees avec Roboflow (format YOLO)

Resultat : mAP attendu : 0.55 a 0.70

Phase 3 — Validation et test

Evaluer les vraies performances du modele sur des donnees qu'il n'a jamais vues pendant l'entrainement.

- + cubeai/road-damage-detection-for-yolov8 (test rapide YOLOv8)
- + Images terrain Meknes non vues pendant l'entrainement

Resultat : mAP cible final : ≥ 0.55

Pourquoi cette combinaison est la meilleure :

- RDD2022 fournit la diversite (6 pays, 47K images) pour eviter l'overfitting
- lorenzoarcioni apporte la proprete et la fraicheur (2026) des annotations
- Le dataset marocain local est LA valeur ajoutee unique du projet — inexistant dans la litterature
- cubeai permet de tester rapidement sans conversion de format

7. Comment telecharger dans Google Colab

Code complet pret a coller dans Google Colab :

Cellule 1 — Configurer Kaggle

```
# Remplace par tes vraies valeurs import os KAGGLE_TOKEN =  
"KGAT_6ed695a127affd8e407c4f90393065b6" KAGGLE_USERNAME = "TON_USERNAME_KAGGLE"  
os.makedirs("/root/.kaggle", exist_ok=True) with open("/root/.kaggle/kaggle.json", "w") as  
f: f.write(f'{{"username":"{KAGGLE_USERNAME}","key":"{KAGGLE_TOKEN}"}}')  
os.chmod("/root/.kaggle/kaggle.json", 0o600) !pip install kaggle -q print("Kaggle  
configure !")
```

Cellule 2 — Monter Google Drive

```
from google.colab import drive drive.mount('/content/drive') import os  
os.makedirs('/content/drive/MyDrive/RoadScan_MA/data', exist_ok=True) print("Drive monte  
!")
```

Cellule 3 — Telecharger RDD2022 (10-15 min)

```
!kaggle datasets download \ -d aliabdelmenam/rdd-2022 \ -p  
/content/drive/MyDrive/RoadScan_MA/data/ print("Telechargement termine !")
```

Cellule 4 — Decompresser

```
!unzip -q \ /content/drive/MyDrive/RoadScan_MA/data/rdd-2022.zip \ -d  
/content/drive/MyDrive/RoadScan_MA/data/RDD2022/ print("Decompression terminee !")
```

Cellule 5 — Verifier la data

```
import os chemin = '/content/drive/MyDrive/RoadScan_MA/data/RDD2022' total = 0 for pays in  
sorted(os.listdir(chemin)): c = f"{chemin}/{pays}/images" if os.path.exists(c): nb =  
len(os.listdir(c)) total += nb print(f"{pays}: {nb} images") print(f"TOTAL : {total}  
images")
```

8. Tableau de decision rapide

Utilise ce tableau pour evaluer n'importe quel dataset trouve sur internet en moins de 2 minutes.

Question a poser	Reponse OUI	Reponse NON	Action
Usabilite > 0.75 ?	Continuer	Verifier les annotations	Eviter si < 0.5
Telechargements > 1000 ?	Dataset fiable	Verifier les commentaires	Prudence si < 100
Format YOLO disponible ?	Parfait	Conversion necessaire	Script Python requis
Mis a jour < 2 ans ?	Utiliser	Verifier contenu	Chercher alternative
Ressemble aux routes marocaines ?	Priorite haute	Priorite basse	Utiliser en complement
Annotations visibles et propres ?	Utiliser	Re-annoter ou eviter	Verifier manuellement
Grand dataset (> 5000 images) ?	Base d'entrainement	Complement ou fine-tuning	Combiner avec d'autres

Ordre de priorite des sources :

Priorite	Source	Raison
1er	Roboflow Universe	Format YOLOv8 direct, zero conversion, specialise CV
2eme	Kaggle	Grande quantite, API Colab, filtrage par usabilite
3eme	Papers With Code	Datasets valides scientifiquement, benchmarks
4eme	GitHub chercheurs	Datasets des chercheurs marocains et africains
5eme	Google Dataset Search	Si introuvable ailleurs, agregge tout le web

Combinaison finale recommandee pour RoadScan-MA

rdd-2022 (47K images) + lorenzoarcioni (2K propres) + Dataset Meknes (200-500 images locales)

Cette combinaison garantit : diversite internationale + proprete des annotations + adaptation locale marocaine